

**Instituto Tecnológico y de Estudios Superiores de Monterrey**



**Procesamiento de imágenes médicas para el diagnóstico (Gpo 300)**

**Diagnóstico por Computadora**

Carlos Enrique López Jimenez A01283855

Genaro Gallardo Bórquez A01382459

Claudia Esmeralda González Castillo A01411506

Jesus Eduardo Martinez Herrera A01283785

Mario Veccio Castro Berrones A00826824

14 de junio del 2022

## **Introducción**

La segmentación de imágenes es una tarea que se podría interpretar como una generalización de la detección de contornos. El objetivo de la segmentación es separar distintas regiones de una imagen basada en sus diferencias perceptuales. Ésta técnica de procesamiento se realiza con la finalidad de extraer información útil de una escena para facilitar la observación y análisis de la misma. Esto es debido a que el resto del contenido puede estar contaminado o simplemente no tiene utilidad para lo que se está buscando.

En términos médicos, se recibe una entrada digital en tonos grises que representa una región anatómica y su salida se constituye de un conjunto de regiones poligonales catalogadas por un criterio predeterminado.

El entrenamiento de una máquina es el método para crear algún algoritmo o modelo que pueda evaluar una segmentación de imágenes y posteriormente sea útil para realizar pruebas.

## **Objetivo**

La finalidad de este trabajo es explorar distintos escenarios y métodos de clasificación para determinar cuales presentan un mejor desempeño en las métricas de evaluación utilizadas.

## **Marco Teórico**

Cuando se habla del procesamiento de imágenes digitales y la visión por computadora es forzoso el mencionar la segmentación de imágenes. Este es el proceso de dividir una imagen digital en múltiples segmentos los cuáles, por lo general, son conocidos como conjuntos de píxeles u objetos de imagen. El principal fin que tiene esta es poder simplificar y/o cambiar la representación de una imagen en algo más significativo y que a su vez sea más fácil de analizar. Es un proceso muy importante a tener en cuenta, en especial cuando se busca localizar objetos o límites en específico de una imagen. Se le podría llamar como un proceso de etiquetado a cada píxel de manera que aquellos con la misma etiqueta compartan ciertas características.

Como resultado de estas segmentaciones se obtiene un conjunto de segmentos que cubre colectivamente toda la imagen. Cada píxel que se encuentra en una región en específico es similar a otro con respecto a alguna característica o propiedad calculada por el sistema. Algunas de estas características son: color, intensidad o textura. Todas las regiones adyacentes son identificadas con un color significativamente diferente con respecto a aquellas con las mismas características (Shapiro, G. & Stockman, G., 2000). Al aplicarse este proceso en un conjunto de imágenes médicas, los contornos resultantes después de la segmentación pueden ser usados para crear reconstrucciones con el apoyo de algunos algoritmos de interpolación como cubos de marcha (Zachow, S. et al., 2007).

Previamente a realizar los procedimientos se investigó un poco acerca de las herramientas que se utilizarían para tener un mejor entendimiento de estas y poder implementarlas adecuadamente.

Segmentación de imágenes: es una técnica de procesamiento en la que se extrae información útil de una escena con el fin de observar y analizar con mayor facilidad. Se hace esta división debido a que el contenido restante de la imagen podría estar contaminado por ruidos o información que no cumple con el propósito del análisis que se realice. En general, los algoritmos de segmentación están basados en 2 propiedades básicas de los valores del nivel de gris: discontinuidad o similitud entre los grises de los diversos píxeles (UNAM, s.f.) (La Serna, N. & Roman, U., 2009).

Matriz de confusión: es una herramienta que permite la visualización del desempeño de un algoritmo que se emplea en aprendizaje supervisado para así mismo evaluar el modelo de predicción del mismo. La cantidad de predicciones se resumen en los valores de conteo y de desglose por cada clase. Existen 2 filas: positiva y negativa. En cada una de estas se pueden ubicar los verdaderos positivos y negativos los cuáles así se han organizado arbitrariamente. De esta manera se puede saber cuando un valor es verdadero o falso para determinar el error que presenta el algoritmo (Interactive Chaos, s.f.) (Barrios, J., 2019).

Curvas ROC: Es una gráfica que desempeña la sensibilidad y especificidad de cada uno de los puntos de corte en un examen diagnóstico de una escala de medición que es continua. Estas se consideran parte de un método de análisis estadístico para determinar la exactitud diagnóstica de las pruebas que se llevan a cabo. Por lo general se busca que cumplan con 3 propósitos: determinar el punto de corte de una escala continua en el que se alcanza la sensibilidad y especificidad más alta, evaluar la capacidad discriminativa del test diagnóstico. Esto se refiere a la capacidad de diferenciar entre, por ejemplo, sana de los sujetos contra los enfermos. Cuando se comparan las capacidades discriminativas de 2 o más tests diagnósticos se pueden expresar sus resultados como escalas continuas (Cerdeira, J. & Cifuentes, L., 2012).



## **Metodología**

Como equipo, lo que hicimos fue modificar la dirección de los archivos en el código brindado por los documentos y clases que tuvimos para que los datos pudieran ser cambiados y así modifiquen los números de repeticiones por metodo, de 100 a 10, la trainfraction la pusimos en .7 y nos aseguramos que el sampling type fuera balanceado, llegamos a una decisión de utilizar el método de naive bayes y naive bayes BE, esto porque es uno de los algoritmos más sencillos de utilizar para la clasificación que se basa en el teorema de Bayes con una suposición de independencia entre los predictores, este es fácil de construir y comúnmente útil para conjuntos de datos muy grandes.

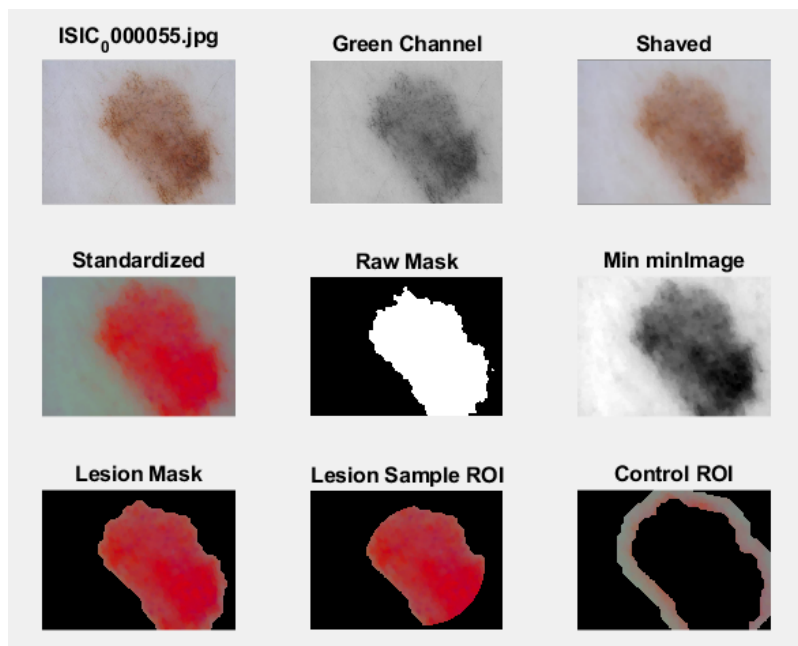
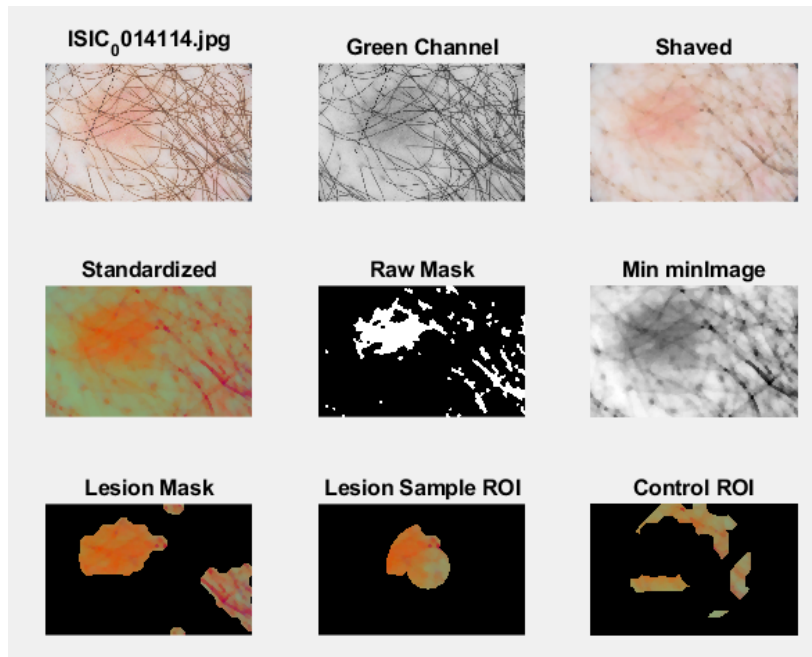
## Resultados

Resultados de segmentación:

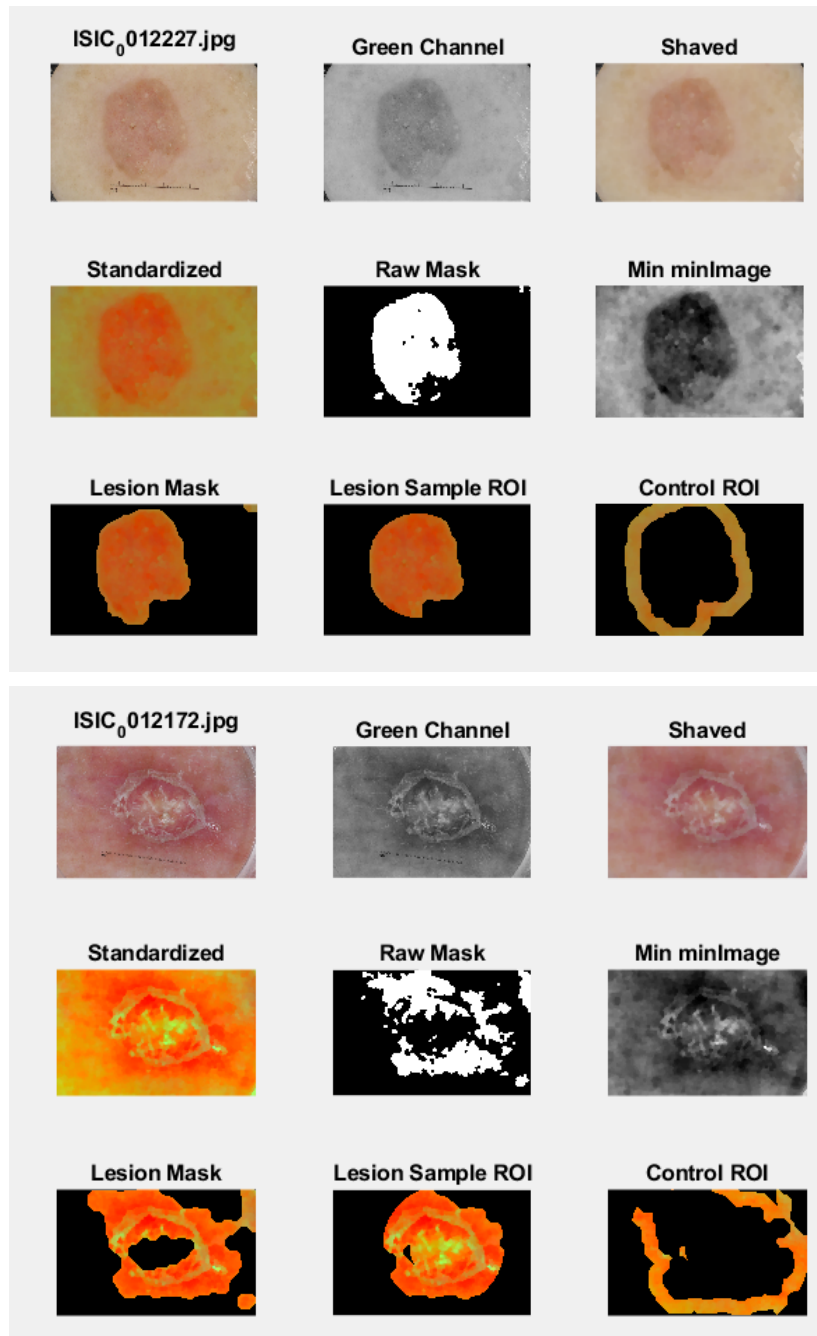
Melanoma



## Nevus



## Seborrheic



Al obtener los datos de la segmentación, se insertan en tres diferentes códigos de R, éstos crean Heatmaps, donde se distribuyen las características e información de los datos.

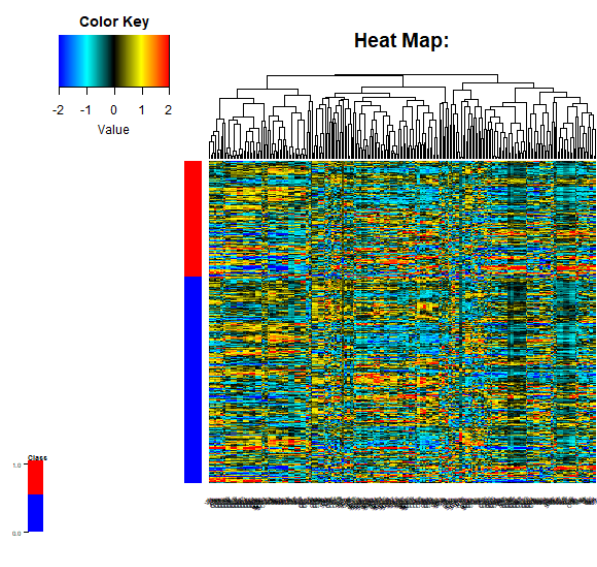


Figura 7. Heatmap MelanomaVSSeborrheicVSNovus

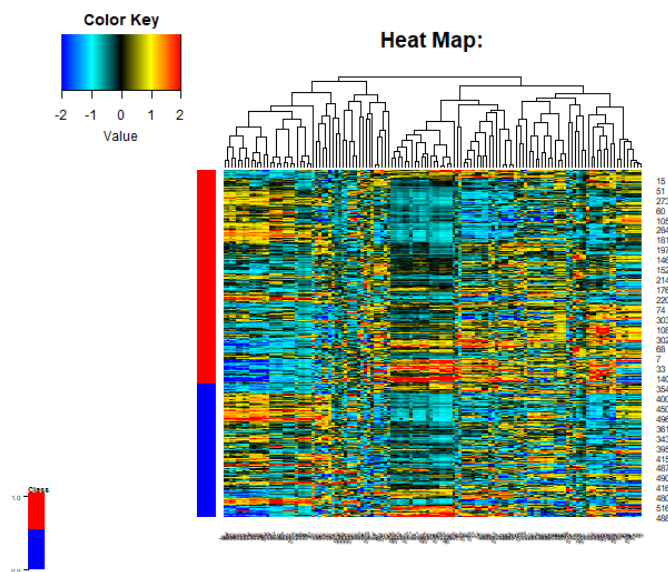


Figura 8. Heatmap Melanoma VS Seborrheic (RAT)

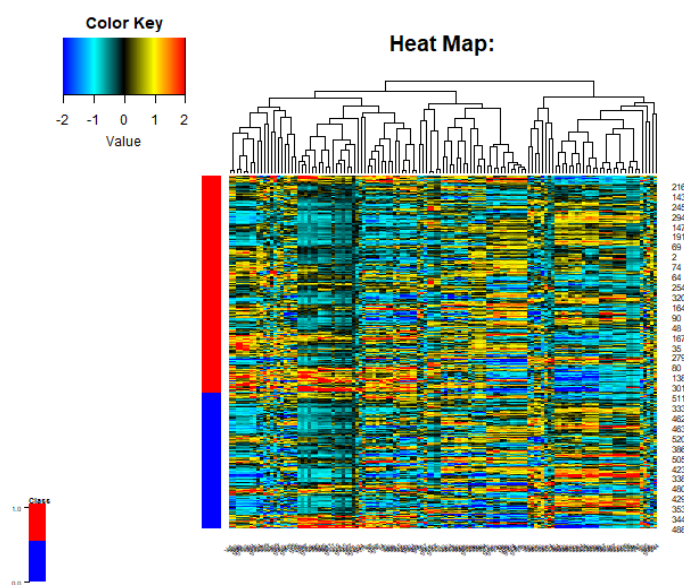


Figura 9. Heatmap Melanoma VS Seborrheic (TALLER)

Posteriormente, se obtienen las curvas ROC y las matrices de confusión con el método Naive Bayes. Este proceso se hace de igual manera en los tres códigos.

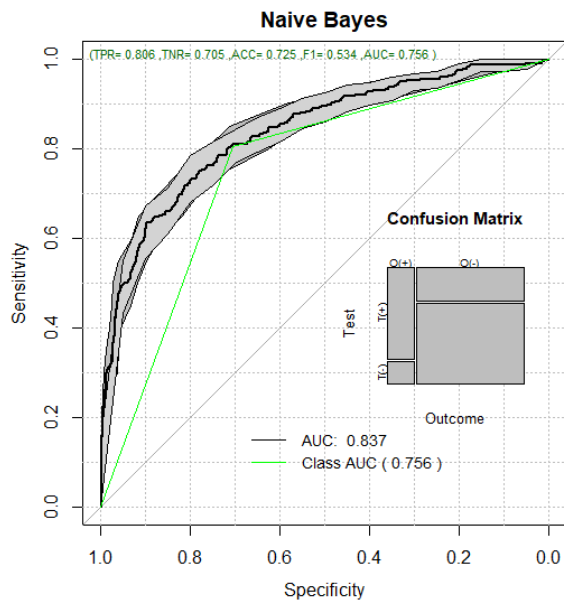


Figura 10. Curva ROC y Matriz de confusión  
MelanomaVSSeborrheicVSNovus

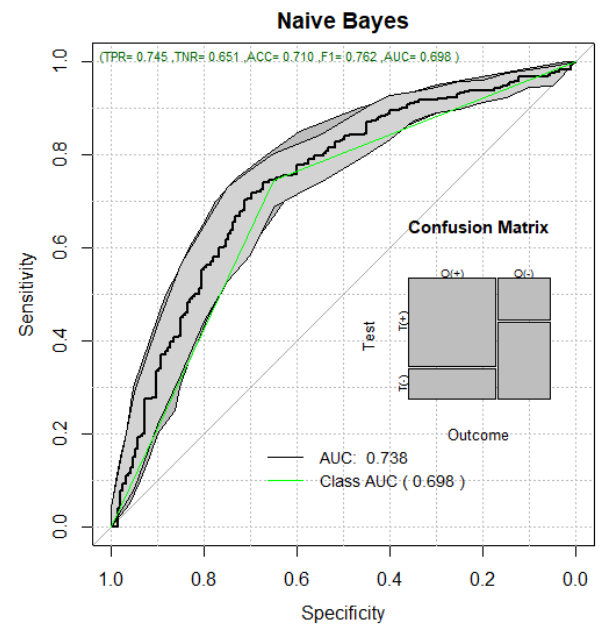


Figura 11. Curva ROC y Matriz de Confusión  
Melanoma VS Seborrheic (RAT)




Figura 12. Curva ROC y Matriz de confusión  
Melanoma VS Seborrheic (Taller)

## Discusión



Al hacer el diagnóstico por computadora de las imágenes es necesario hacer mención de las máquinas de aprendizaje. El diagnóstico de imágenes empieza con el aprendizaje de la máquina, está busca identificar los patrones en los datos que recibe para intentar predecir el diagnóstico de las imágenes.

Por medio del análisis de los parámetros podemos identificar que tan sensibles y específicos son los resultados de las máquinas, usando las curvas ROC podemos ver como tenemos resultados informativos que ayudan a entender cómo funciona nuestra máquina.

## Conclusiones

**Jesús:** En los últimos años, se ha desarrollado ampliamente el área de aplicaciones de machine learning para el temprano diagnóstico de enfermedades. Esto es de suma importancia y relevancia para el área de la salud ya que no solo facilita el diagnóstico que recibe el paciente sino también el proceso que el personal de salud debe realizar. En cuanto al cáncer de piel, es de alta utilidad para primero detectar melanomas antes de que evolucionen a cáncer de piel.

**Esmeralda:** Conforme avanza la tecnología es importante siempre buscar maneras de mejorar algunas técnicas, tales como las de diagnóstico de imágenes en medicina. Machine Learning forma gran parte de las nuevas técnicas de diagnóstico, solo es necesario entrenar a la máquina para que se enfoque en analizar ciertos datos y que podamos obtener un resultado muy preciso, esto principalmente es importante para evitar errores al trabajar en una área como lo es medicina.

**Mario:** existen diversas áreas en donde se puede aplicar Machine Learning, ejemplo de esto es el análisis de imágenes para un posterior diagnóstico. Existen diversos algoritmos o técnicas que se utilizan para estos procesos aunque dependiendo del análisis que se quiera hacer es la técnica que se usa. Actualmente es un área que, a pesar de tener sus aplicaciones, tiene mucha oportunidad ya que se debe seguir probando e investigando para que tenga mayores aplicaciones. A su vez, esto permite que estas técnicas se vayan mejorando para brindar mejores diagnósticos.

**Genaro:** La tecnología de machine learning ha tenido un auge muy reciente en el área médica. Los avances que ha tenido esta área son impactantes, tiene mucho potencial para ser muy importante e incluso indispensable para el temprano diagnóstico de enfermedades como las vistas en este reporte. Aún hay mucho que trabajar al respecto, pero sin ninguna duda es un área que vale la pena seguir desarrollando.

**Carlos:** Gracias a esta materia puede desarrollar nuevos conocimientos los cuales me han ayudado a realizar todas las actividades y retos los cuales se me han está presentando a lo largo del semestre, así como también pude notar el gran impacto que tiene las aplicaciones de machine learning ya que estas ayudan al diagnóstico temprano de enfermedades, por ende esto es un gran apoyo tanto para los doctores como al mismo paciente, la enfermedad que más detona en este específico tema es el cáncer de piel, ya que gracias a las imágenes emitidas por la máquina y el software el doctor puede tomar medidas preventivas antes de que este sea muy difícil de parar.

## Referencias

- Shapiro, G. & Stockman, G. (2000). *Computer Vision*, págs. 279–325, Nueva Jersey, Prentice-Hall, ISBN 0-13-030796-3. The University of Washington. Recuperado de: [http://nana.lecturer.pens.ac.id/index\\_files/referensi/computer\\_vision/Computer%20Vision.pdf](http://nana.lecturer.pens.ac.id/index_files/referensi/computer_vision/Computer%20Vision.pdf)
- Zachow, S. et al. (2007). 3D Reconstruction of Individual Anatomy from Medical Image Data: Segmentation and Geometry Processing. Recuperado de: [https://opus4.kobv.de/opus4-zib/frontdoor/deliver/index/docId/1044/file/ZR\\_07\\_41.pdf](https://opus4.kobv.de/opus4-zib/frontdoor/deliver/index/docId/1044/file/ZR_07_41.pdf)
- Universidad Nacional Autónoma de México (s.f.). *Capítulo 1. Antecedentes de los métodos de Segmentación*. Obtenido de: <http://www.ptolomeo.unam.mx:8080/xmlui/bitstream/handle/132.248.52.100/171/A4.pdf>
- La Serna, N. & Roman, U. (2009). *Técnicas de Segmentación en Procesamiento Digital de Imágenes*. Facultad de Ingeniería de Sistemas e Informática, Universidad Nacional Mayor de San Marcos. Recuperado de: [https://sisbib.unmsm.edu.pe/BibVirtual/Publicaciones/risi/2009\\_n2/v6n2/a02v6n2.pdf](https://sisbib.unmsm.edu.pe/BibVirtual/Publicaciones/risi/2009_n2/v6n2/a02v6n2.pdf)
- Interactive Chaos (s.f.). *Matriz de Confusión*. Recuperado de: <https://interactivechaos.com/es/manual/tutorial-de-machine-learning/matriz-de-confusion>
- Barrios, J. (2019). *La matriz de confusión y sus métricas*. Health: Big Data. Recuperado de: <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/>
- Microsoft (2022). *Resultados de los modelos de aprendizaje automático*. Recuperado de: <https://docs.microsoft.com/es-es/dynamics365/finance/finance-insights/confusion-matrix>
- Cerda, J. & Cifuentes, L. (2012). *Uso de curvas ROC en investigación clínica: Aspectos teórico-prácticos*. Revista chilena de infectología, 29(2), páginas 138-141. DOI: <https://dx.doi.org/10.4067/S0716-10182012000200003>